2021

IN2010

OBLIG 3

SVEIN-GISLE SÆTRE

Oblig 3

Deloppgave 1: Korrekthet

Foruten algoritmene Insertion sort og Quicksort har jeg implementert:

ICantBelieveItCanSort

Dette var en algoritme som ble vist frem i forelesning da den er så lite intuitiv. Herfra og ut vil jeg referere til den forkortet som **ICBICS**. Implementasjonen er derimot meget enkel, som gjør at jeg ikke tror den trenger noen ekstra forklaringer. Ved behov er den uansett ganske nøye forklart på https://arxiv.org/pdf/2110.01111v1.pdf.

Algoritmen kjører i $O(n^2)$ da den har to forløkker. For hver i kjører j også gjennom alle elementer. Den gjør også veldig mange unødvendige bytter, som gjør det til en veldig lite effektiv algoritme, men den fungerer.

Heapsort

Heapsort er en algoritme som vist i forelesning der vi benytter oss av en Maxheap for å kunne sortere elementene.

Algoritmen kjører i $O(n_{log}n)$.

Test av algoritmene

For å teste algoritmene har jeg utvidet runAlgsPart1 i Oblig3Runner.java til å lese gjennom filene som blir generert for å sjekke om noen tall er mindre enn det forrige tallet i filen. Dette vil printe en feilmelding og vise tallene som er feilsorterte.

Deloppgave 2: Sammenligninger, bytter og tid

Sammenligninger er målt ved bruk av hjelpefunksjonene fra pre-koden. Alle sammenligninger i løkker og ellers er gjort ved bruk av funksjonene lt, gt, geq etc.

For bytter prøvde jeg å bruke funksjonen swap, men støtte borti noen indekseringsfeil når jeg brukte den som jeg ikke klarte å finne ut av. Jeg har da heller manuelt inkrementert swaps-variabelen hver gang et bytte utføres.

Deloppgave 3: Eksperimentér

I hvilken grad stemmer kjøretiden overens med kjøretidsanalysene (store O) for de ulike algoritmene?

For å se på om algoritmene sin kjøretid stemmer overens med kjøretidsanalysene har jeg satt opp kurver for algoritmene i både nesten sortert og tilfeldig materiale for å se om kurvene har den stigningen som man skulle kunne forvente av deres O-notasjon. Det er noen forskjeller i hvor langt kurvene går da det tok for lang tid å teste noen av algoritmene på de store filene, men man ser likevel tendensene i kurvene jeg har fremstilt.

Insertion

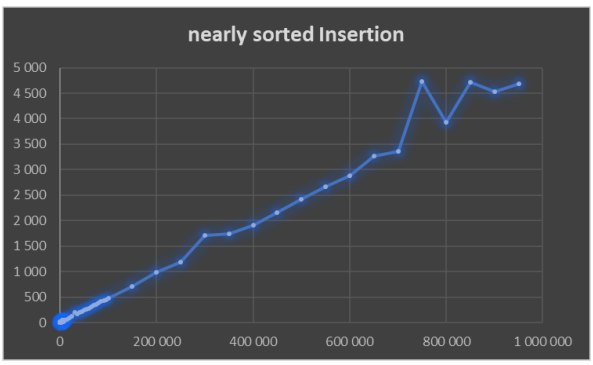

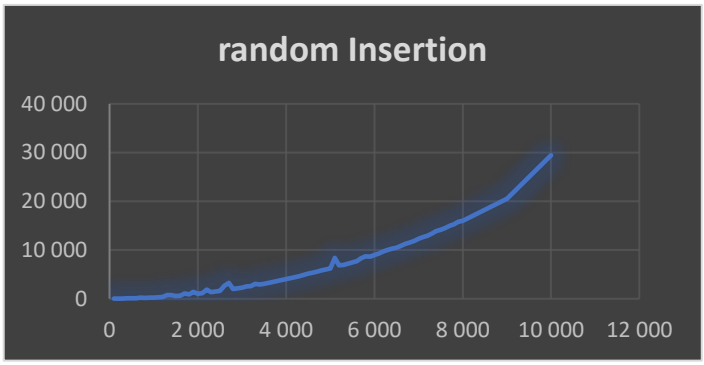

Når tallmaterialet nesten er sortert kan
Insertion, sett vekk fra noen utliggere, nesten se ut som den er lineær, eller iallfall nærmere $O(n_{log}n)$ enn $O(n^2)$ som algoritmen skal kjøre i, i verste tilfelle. Ved tilfeldig tallmateriale ser man nærmere tendensen til n^2-stigningen man skulle forvente. Ved et nesten sortert tallmateriale trenger ikke Insertion sort å gjøre mange bytter, og kan fort bryte ut av løkken sin som gjør den en del raskere. Ved en sortert liste vil insertion bare gå gjennom listen, så en nesten sortert liste vil altså gå mot $O(n)$ jo mer sortert listen er.

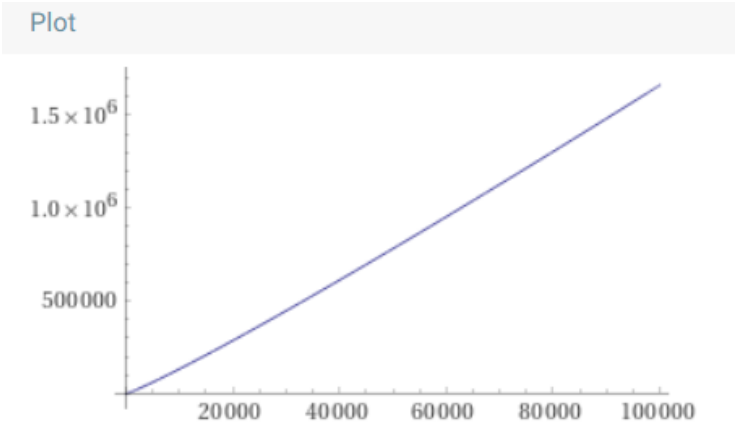

$n_{log}n$ tegnet i wolframalpha, som har en svak kurve oppover i motsetning til den lineære stigning som ikke har noen kurve.

Quick sort

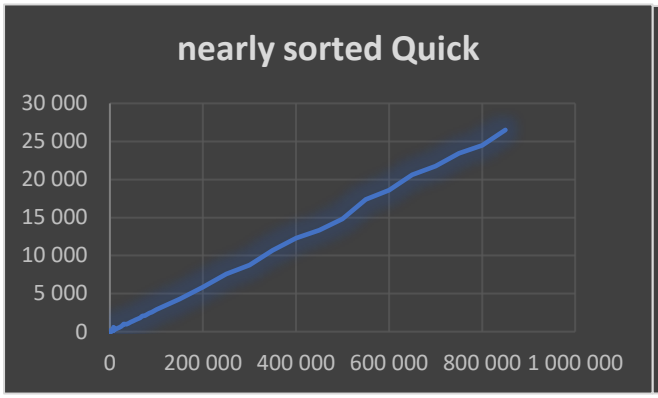

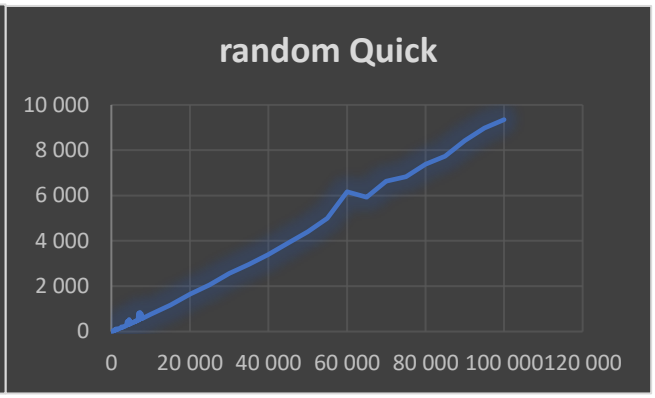

Quick sort ser både i nesten sortert og tilfeldig tallmateriale ut som den ligger nærmere $O(n_{log}n)$ enn $O(n^2)$. Som forklart i forelesning er det veldig sjelden at man kommer ut for det verste tilfellet til Quicksort, så O-notasjonen kan i dette tilfellet være misvisende.

I Can't Believe It Can Sort

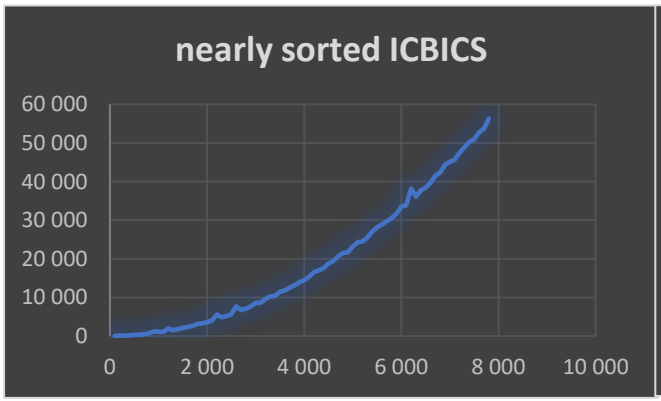

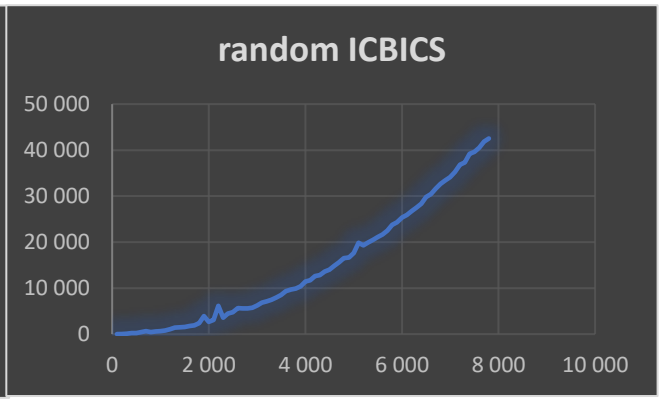

På ICBICS kan man tydelig se n^2-stigningen i både nesten sortert og tilfeldig tallmateriale. Algoritmen har heller ingen forbedringer ved et nesten sortert materiale, da den vil bytte om på tall unødig mange ganger likevel.

Heapsort

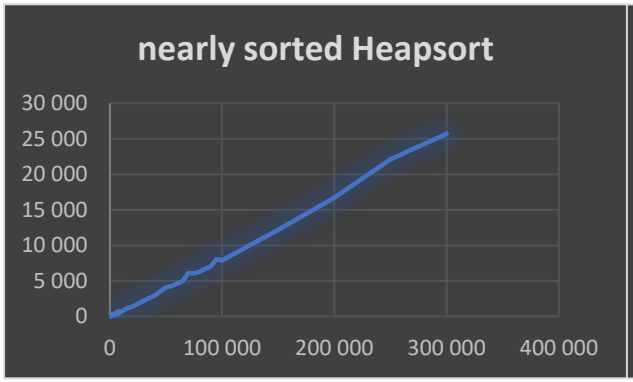

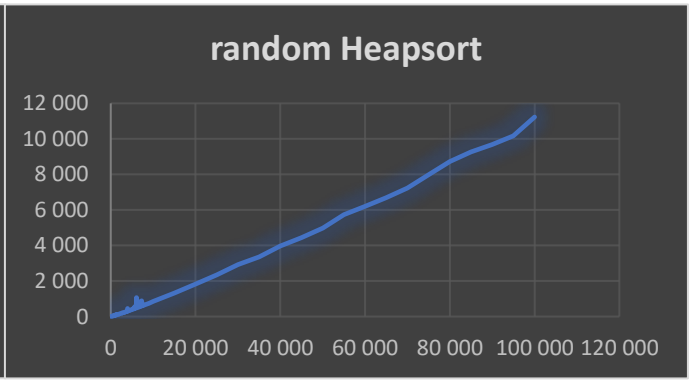

Heapsort er $O(n_{log}n)$ og begge kurvene ser ut til å ligne på en slik stigning også.

Hvordan er antall sammenligninger og antall bytter korrelert med kjøretiden?

Korrelasjon mellom kjøretid og bytter							
Random				NearlySorted			
Ins	Qck	ICBICS	Heap	Ins	Qck	ICBICS	Heap
0,918628	0,999998	0,999961	1	0,998438	0,999977	0,993701	0,999997
Korrelasjon mellom kjøretid og sammenligninger							
Random				NearlySorted			
Ins	Qck	ICBICS	Heap	Ins	Qck	ICBICS	Heap
0,918656	0,999996	0,999961	1	0,998426	0,999584	0,999958	0,999998

Ved å bruke korrelasjons-funksjonen i Excel ser vi at korrelasjon mellom kjøretid og bytter/sammenligninger nesten er perfekt. Insertion sort har derimot en litt svakere korrelasjon enn de andre algoritmene.

Hvilke sorteringsalgoritmer utmerker seg positivt når n er veldig liten? Og når n er veldig stor?

nearly_sorted kjøretid				
n	Insertion	Quick	ICantBelieveItCanSort	Heapsort
10	8	37	16	39
100	515	905	5 578	835

random kjøretid				
n	Insertion	Quick	ICantBelieveItCanSort	Heapsort
10	16	42	17	37
100	3 983	1 390	7 108	1 112

Tabellene over ser på total kjøretid for sortering av alle n opp til n. For f. eks n=10 har vi kjøretiden for alle n fra det tomme arrayet opp til 10 n.

Når n er veldig liten (< 100) ser vi at insertion og litt overraskende ICantBelieveItCanSort utmerker seg positivt. Kjøretiden deres er under halvparten av Quicksort og Heapsort. Når n blir 100 ser vi derimot at dette ikke lenger holder, særlig for ICBICS som fort faller av løpet.

nearly_sorted kjøretid				
	Insertion	Quick	ICBICS	Heapsort
10	0	0	1	0
100	3	5	19	7
1 000	2	26	1 098	54
7 868	33	209	167 678	537
10 000	43	271		669
100 000	479	2 884		7 894
312 187	1 490	9 445		27 093
867 029	**4 595**	**26 327**		
989 661	**4 779**			

random kjøretid				
	Insertion	Quick	ICBICS	Heapsort
10	0	0	1	0
100	51	6	14	6
1 000	259	60	669	66
8 244	38 054	612	116 068	677
10 000	29 438	**760**		**843**
100 000		9 349		11 230

Tabellene over ser np på kjøretid for sortering av denne spesifikke n. For f. eks n=10 har vi kjøretiden for sorteringen på størrelsen n.

For tallmaterialet som er nesten sortert ser vi at insertion sort utmerker seg, mens for tilfeldig materiale utmerker Quick sort og Heapsort seg positivt.

Hvilke sorteringsalgoritmer utmerker seg positivt for de ulike inputfilene?

Når tallmateriet nesten er sortert utmerker Insertion sort seg veldig positivt og har en mye mindre kjøretid enn både Quick sort og Heapsort. Quick sort som har ganske lik kjøretid som Heapsort i tilfeldig tallmateriale viser seg også å være mye raskere enn Heapsort når tallmaterialet nesten er sortert.

Har du noen overraskende funn å rapportere?

Det mest overraskende er at Insertion sort er så mye bedre enn både Quick sort og Heapsort når tallmaterialet nesten er sortert. Når man ser på korrelasjonen mellom kjøretid og bytter/sammenligninger og antall bytter/sammenligninger i Insertion sort er det derimot ikke så ufattelig. Ved et nesten sortert tallmateriale må Insertion gjøre **langt** færre bytter og sammenligninger enn både Quick sort og Heapsort.

Nesten sortert materiale:

Swaps	Insertion	Quick	ICBICS	Heapsort
10	3	13	16	56
100	39	137	178	1 392
1 000	461	1 322	1 829	22 583
7 868	3 576	10 312	14 445	237 391
10 000	4 566	13 280		310 416
100 000	45 929	134 144		3 946 280
312 187	**143 919**	**412 880**		**13 585 111**
867 029	**400 703**	**1 156 686**		
989 661	457 277			
Comparisons	Insertion	Quick	ICBICS	Heapsort
10	34	119	221	167
100	376	1 750	20 201	3 270
1 000	3 920	24 330	2 002 001	49 623
7 868	30 754	239 520	123 826 585	510 109
10 000	39 130	319 362		668 599
100 000	391 856	3 855 964		8 363 222
312 187	**1 224 397**	**12 983 349**		**28 662 599**
867 029	**3 402 491**	**39 367 869**		
989 661	3 883 535			

Det andre som er overraskende er hvor rask Quick sort er i forhold til Heapsort. Quick sort som er $O(n^2)$ burde intuitivt være treigere enn Heapsort som er $O(n_{log}n)$, men om vi ser på antall bytter og sammenligninger ser vi at Quick sort trenger å gjøre langt færre enn Heapsort, spesielt bytter. Dette er nok grunnen til at Quick sort holder så nært følge med Heapsort. Som nevnt tidligere er det også veldig sjelden at Quick sort faktisk kjører i verste tilfelle, så mye oftere er den nærmere $O(n_{log}n)$.

Usortert materiale:

Swaps	Insertion	Quick	ICBICS	Heapsort
10	29	14	33	48
100	2 704	214	2 712	1 271
1 000	249 411	3 013	247 983	20 753
8 244	16 940 361	30 748	16 449 021	233 592
10 000	24 925 372	**37 831**		**290 799**
100 000		**457 397**		**3 737 865**
Comparisons	Insertion	Quick	ICBICS	Heapsort
10	83	128	221	157
100	5 700	2 393	20 201	3 115
1 000	501 809	36 764	2 002 001	47 139
8 244	33 905 441	400 417	135 943 561	513 009
10 000	49 880 731	**492 026**		**638 213**
100 000		**6 268 515**		**8 044 928**